

# Análise de Regressão Linear Múltipla: Modelando o Retorno Mensal do Ibovespa

Luis Guilherme Souto Miranda  
Luís Fernandes Saucedo Souza

October 16, 2025

## Abstract

Este trabalho explora o uso da Regressão Linear Múltipla para modelar o retorno mensal do Ibovespa (BVSP) com base em variáveis macroeconômicas: a variação do dólar, a taxa Selic e a inflação (IPCA), a partir de janeiro de 2020. Utilizando a linguagem R, realizamos a coleta dos dados, o ajuste do modelo, a avaliação de sua performance e uma análise detalhada dos resíduos para validar as suposições do modelo. São apresentados e discutidos os principais resultados, incluindo o coeficiente de determinação, a análise de multicolinearidade através do Fator de Inflação de Variância (VIF), e a verificação das premissas do modelo de regressão.

## 1 Introdução

O modelo de regressão é uma ferramenta estatística poderosa para analisar a relação entre variáveis. Na Regressão Linear Múltipla (RLM), o objetivo é modelar a relação entre uma variável resposta,  $Y$ , e um conjunto de variáveis explicativas (ou preditoras),  $X_1, X_2, \dots, X_p$ . Este modelo permite avaliar a influência conjunta de múltiplos fatores sobre a variável de interesse.

O modelo matemático para a Regressão Linear Múltipla é expresso como:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + e_i, \quad i = 1, \dots, n$$

Onde:

- $y_i$  é o valor observado da variável resposta para a  $i$ -ésima observação.
- $x_{ij}$  é o valor observado da  $j$ -ésima variável explicativa para a  $i$ -ésima observação.
- $\beta_0, \beta_1, \dots, \beta_p$  são os parâmetros (coeficientes) do modelo.
- $e_i$  é o erro aleatório, que representa a variação em  $Y$  não explicada pelas variáveis preditoras. Supõe-se que os erros sejam independentes, com média zero e variância constante  $\sigma^2$ .

Neste estudo, o modelo de RLM é aplicado para investigar como o retorno mensal do Ibovespa (variável resposta) é influenciado pelos retornos mensais do dólar, pela taxa Selic mensal e pela variação mensal do IPCA (variáveis preditoras).

## 2 Metodologia

### 2.1 Coleta e Preparação dos Dados

Os dados foram coletados a partir de diversas fontes utilizando pacotes da linguagem R. Os dados do Ibovespa (BVSP) e da cotação do Dólar (BRL=X) foram extraídos do portal Yahoo Finance com o auxílio do pacote `quantmod`. Os dados da taxa Selic (série 432) e do IPCA (série 433) foram obtidos do Sistema Gerenciador de Séries Temporais do Banco Central do Brasil, utilizando o pacote `GetBCBData`. O período de análise compreende de 1 de janeiro de 2020 até a data atual.

Após a coleta, os dados foram transformados para uma frequência mensal. Os retornos do Ibovespa e do Dólar foram calculados como a diferença logarítmica percentual dos preços de fechamento mensais. A taxa Selic, originalmente diária, foi convertida para uma taxa mensal efetiva. Por fim, todas as séries foram consolidadas em um único dataframe para a análise.

## 2.2 Ajuste do Modelo

A estimação dos parâmetros  $\beta_0, \beta_1, \dots, \beta_p$  foi realizada pelo método dos Mínimos Quadrados Ordinários (MQO). Este método busca os coeficientes que minimizam a Soma dos Quadrados dos Erros (SQE), definida como:

$$Q(\beta_0, \dots, \beta_p) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_p x_{ip})^2$$

O ajuste do modelo foi implementado em R utilizando a função `lm(ticket ~ dolar + selic_mensal + ipca)`.

## 3 Resultados e Discussão

### 3.1 Análise Descritiva

Gráficos de dispersão foram gerados para visualizar a relação entre o retorno do Ibovespa e cada uma das variáveis preditoras. Observando as Figuras 1, 2 e 3, não se nota uma relação linear forte e clara em nenhuma das análises bivariadas, o que justifica a utilização de um modelo múltiplo para capturar as interações conjuntas.




Figure 1: Gráfico de dispersão dos retornos do Ibovespa vs. Dólar.




Figure 2: Gráfico de dispersão dos retornos do Ibovespa vs. Selic Mensal.




Figure 3: Gráfico de dispersão dos retornos do Ibovespa vs. IPCA.

### 3.2 Sumário do Modelo de Regressão

O ajuste do modelo resultou nos coeficientes apresentados na Figura 4. A equação do modelo de regressão ajustado é:

$$\widehat{Ticket}_{previsto} = 4.601 - 1.293 \times dolar - 1.689 \times selic\_mensal - 4.064 \times ipca$$

```

> coef_final <- coef(modelo_completo)
> coef_final
              (Intercept)      dados_df$dolar dados_df$selic_mensal      dados_df$ipca
              4.600818         -1.293388         -1.688921         -4.064087
> cat("Ticket_previsto =",
+     round(coef_final[1], 3), "+",
+     round(coef_final[2], 3), "* dolar +",
+     round(coef_final[3], 3), "* selic_mensal +",
+     round(coef_final[4], 3), "* ipca")
Ticket_previsto = 4.601 + -1.293 * dolar + -1.689 * selic_mensal + -4.064 * ipca
>

```

Figure 4: Coeficientes finais do modelo de regressão e equação resultante.

Para avaliar a qualidade do ajuste, foram calculadas as métricas de performance apresentadas na Figura 5. O Coeficiente de Determinação ( $R^2$ ) foi de 0.5689, indicando que aproximadamente 56.9% da variabilidade no retorno do Ibovespa é explicada pelas variáveis preditoras no modelo, o que representa um ajuste robusto.

```

> # y_real é a variável dependente usada no modelo
> y_real <- modelo_completo$model[[1]] # pega a primeira coluna do modelo, que é ticket
> # y_previsto são os valores ajustados
> y_previsto <- fitted(modelo_completo)
> # Calcular métricas
> metricas <- data.frame(
+   RMSE = sqrt(mean((y_real - y_previsto)^2)),
+   MAE = mean(abs(y_real - y_previsto)),
+   R2 = summary(modelo_completo)$r.squared
+ )
> metricas
      RMSE      MAE      R2
1 4.591287 3.334559 0.5689398

```

Figure 5: Métricas de performance do modelo: RMSE, MAE e R-quadrado.

### 3.3 Análise de Diagnóstico

A análise de diagnóstico é fundamental para verificar a adequação das suposições do modelo linear. A Figura 6 apresenta o conjunto padrão de gráficos de diagnóstico gerados em R.




Figure 6: Gráficos de diagnóstico para o modelo de regressão.

### 3.3.1 Linearidade e Homocedasticidade

O gráfico de Resíduos vs. Valores Ajustados (canto superior esquerdo) mostra os pontos distribuídos aleatoriamente em torno da linha horizontal em  $y=0$ , sem padrões evidentes. A linha vermelha, que suaviza a tendência, é praticamente plana, indicando que a suposição de linearidade é atendida. O gráfico Scale-Location (canto superior direito) corrobora a suposição de variância constante dos erros (homocedasticidade), pois a linha de tendência também se mostra estável.

### 3.3.2 Normalidade dos Resíduos

O gráfico Q-Q (painel do meio, à esquerda) avalia se os resíduos seguem uma distribuição Normal. Os pontos se alinham quase perfeitamente à linha diagonal teórica, sugerindo que a suposição de normalidade dos resíduos é plenamente satisfeita.

### 3.3.3 Pontos Influentes (Outliers)

O gráfico de Resíduos vs. Alavancagem (painel do meio, à direita) é usado para identificar observações influentes. Não há pontos que ultrapassem as linhas tracejadas da distância de Cook, o que indica a ausência de outliers com influência indevida sobre os coeficientes do modelo.

### 3.3.4 Multicolinearidade

Para verificar a existência de multicolinearidade (correlação forte entre as variáveis preditoras), foi calculado o Fator de Inflação de Variância (VIF), cujos resultados estão na Figura 7.

```

> # Fatores de Inflação da Varância (VIF)
> vif(modelo_completo)
      dados_df$dolar dados_df$selic_mensal      dados_df$ipca
      1.044602      1.086573      1.078239
> # VIF < 5: Multicolinearidade baixa/aceitável
  # VIF entre 5 e 10: Multicolinearidade moderada/preocupante
  # VIF > 10: Multicolinearidade severa

```

Figure 7: Resultado do teste de Fator de Inflação de Variância (VIF).

Como todos os valores de VIF são muito próximos de 1 (e bem abaixo do limiar crítico de 5), podemos concluir que não há problemas de multicolinearidade entre as variáveis preditoras do modelo.

## 4 Conclusão

A análise de regressão linear múltipla demonstrou ser uma abordagem eficaz para modelar o retorno mensal do Ibovespa com base na variação do dólar, na taxa Selic mensal e no IPCA. O modelo ajustado apresentou um bom poder explicativo, com um Coeficiente de Determinação ( $R^2$ ) de aproximadamente 57%. A análise de diagnóstico confirmou a validade das suposições do modelo linear: os resíduos apresentaram comportamento aleatório, homocedástico e aderência à distribuição Normal, sem a presença de pontos influentes ou problemas de multicolinearidade. Isso confere robustez e confiabilidade aos resultados obtidos, sugerindo que as variáveis macroeconômicas selecionadas possuem, em conjunto, uma influência significativa sobre o mercado de ações brasileiro no período analisado.

## References

- [1] Morettin, P. A. and Singer, J. M. (2024). *Estatística e Ciência de Dados*. 2a. Edição. LTC, Rio de Janeiro.
- [2] James, G., Witten, D., Hastie, T. and Tibshirani, R. (2017). *Introduction to Statistical Learning*. Springer.