

# Análise de Regressão Linear Simples: Um Estudo de Caso com Preços de Bitcoin e Ouro

Luís Guilherme Souto Miranda  
Luís Fernandes Saucedo Souza

October 14, 2025

## Abstract

Este trabalho explora o uso da Regressão Linear Simples para analisar a relação entre os preços de fechamento do Bitcoin (BTC-USD) e do fundo de ouro (GLD) a partir de janeiro de 2020. Utilizando a linguagem R, realizamos a coleta de dados, o ajuste do modelo e uma análise detalhada dos resíduos para validar as suposições do modelo. São apresentados e discutidos os principais resultados, incluindo o coeficiente de determinação, a análise de resíduos, a distância de Cook e o gráfico Q-Q, culminando na verificação da autocorrelação dos resíduos através do teste de Durbin-Watson.

## 1 Introdução

Um dos modelos estatísticos mais proeminentes na prática é o de regressão. Na sua forma mais fundamental, a Regressão Linear Simples (RLS), o modelo examina a relação entre duas variáveis contínuas: uma variável explicativa (ou preditora),  $X$ , e uma variável resposta,  $Y$ . O principal objetivo é modelar como a distribuição de probabilidade de  $Y$  pode depender de  $X$ .

O modelo matemático para a Regressão Linear Simples é expresso como:

$$y_i = \alpha + \beta x_i + e_i, \quad i = 1, \dots, n$$

Onde:

- $y_i$  é o valor observado da variável resposta para a  $i$ -ésima observação.
- $x_i$  é o valor observado da variável explicativa para a  $i$ -ésima observação.
- $\alpha$  e  $\beta$  são os parâmetros do modelo.
- $e_i$  é o erro aleatório, que captura a variação em  $Y$  não explicada por  $X$ . Supõe-se que os erros sejam independentes, com média zero e variância constante  $\sigma^2$ .

Neste estudo, o modelo de RLS é aplicado para investigar a relação entre o preço de fechamento diário do Bitcoin (BTC-USD), como variável resposta, e o preço de fechamento do fundo de investimento em ouro (GLD), como variável preditora.

## 2 Metodologia

### 2.1 Coleta e Preparação dos Dados

Os dados foram extraídos do portal Yahoo Finance com o auxílio do pacote `quantmod` na linguagem R. Foram coletados os preços de fechamento diários para os tickers "BTC-USD" e "GLD", abrangendo o período de 1 de janeiro de 2020 até a data atual. As séries temporais foram consolidadas em um único dataframe, e os registros com dados ausentes para qualquer um dos ativos foram excluídos para garantir a consistência da análise.

## 2.2 Ajuste do Modelo

A estimação dos parâmetros  $\alpha$  e  $\beta$  foi realizada pelo método dos Mínimos Quadrados Ordinários (MQO). Este método visa minimizar a Soma dos Quadrados dos Erros (SQE), definida como:

$$Q(\alpha, \beta) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$$

Os estimadores de mínimos quadrados,  $\hat{\alpha}$  e  $\hat{\beta}$ , são calculados pelas seguintes fórmulas:

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$$

O ajuste do modelo foi implementado em R utilizando a função `lm()`.

## 3 Resultados e Discussão

### 3.1 Análise Descritiva

O gráfico de dispersão dos preços de fechamento do Bitcoin versus Ouro é apresentado na Figura 1, juntamente com a reta de regressão ajustada. Observa-se uma tendência linear positiva, sugerindo que preços mais altos do ouro tendem a estar associados a preços mais altos do Bitcoin no período analisado.




Figure 1: Gráfico de dispersão dos preços de BTC-USD vs. GLD com a reta de regressão.

## 3.2 Sumário do Modelo de Regressão

O sumário do ajuste do modelo de regressão linear, obtido através da função `summary()` em R, é apresentado na Figura 2.

```
> summary(analise) # Visualizando um resumo dos dados da análise de regressão linear

Call:
lm(formula = ticket_1 ~ ticket_2, data = dados_df)

Residuals:
    Min       1Q   Median       3Q      Max
-32532 -10050  -2704   8895  37548

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -65881.950   1635.047  -40.29  <2e-16 ***
ticket_2      565.169     8.081    69.94  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 14550 on 1451 degrees of freedom
Multiple R-squared:  0.7712,    Adjusted R-squared:  0.7711
F-statistic: 4892 on 1 and 1451 DF,  p-value: < 2.2e-16
```

Figure 2: Sumário do modelo de regressão linear.

O modelo ajustado é  $\hat{y} = -65881.95 + 565.17x$ . Ambos os coeficientes são estatisticamente significantes (p-valores  $< 2 \times 10^{-16}$ ). O Coeficiente de Determinação ( $R^2$ ) de 0.7712 indica que aproximadamente 77.12% da variação no preço do Bitcoin pode ser explicada pela variação no preço do Ouro, um ajuste consideravelmente forte.

## 3.3 Análise de Diagnóstico

A análise de diagnóstico é fundamental para verificar as suposições do modelo linear.

### 3.3.1 Linearidade e Homocedasticidade

O gráfico de Resíduos vs. Valores Ajustados (Figura 3) é usado para verificar a suposição de linearidade e de variância constante dos erros (homocedasticidade). Idealmente, os pontos deveriam se distribuir aleatoriamente em torno da linha horizontal em  $y=0$ . A linha vermelha, que suaviza a tendência dos resíduos, mostra uma curvatura, sugerindo uma possível quebra na suposição de linearidade.




Figure 3: Gráfico de resíduos versus os valores ajustados pelo modelo.

O gráfico Scale-Location (Figura 4) plota a raiz quadrada dos resíduos padronizados contra os valores ajustados. Este gráfico também serve para verificar a homocedasticidade. A linha vermelha não está perfeitamente horizontal, indicando que a variância dos resíduos pode não ser constante.




Figure 4: Gráfico Scale-Location.

### 3.3.2 Normalidade dos Resíduos

O gráfico Q-Q (Figura 5) é utilizado para avaliar se os resíduos seguem uma distribuição Normal. Se os pontos estiverem alinhados com a reta, a suposição de normalidade é plausível. No gráfico, observa-se que os pontos seguem a reta de perto na maior parte de sua extensão, com desvios nas caudas, o que é comum em dados financeiros. A suposição de normalidade parece ser razoavelmente atendida.




Figure 5: Gráfico Q-Q dos resíduos com bandas de confiança.

### 3.3.3 Pontos Influentes (Outliers)

A análise de pontos de alavancagem (leverage) e outliers é feita pelo gráfico de Resíduos vs. Alavancagem (Figura 6). Pontos com alta alavancagem são "outliers" na variável preditora (X), enquanto pontos com grandes resíduos padronizados são outliers na variável resposta (Y). As linhas tracejadas representam a distância de Cook, que mede a influência de uma observação no resultado da regressão. Não observamos pontos que ultrapassem os limites usuais da distância de Cook, sugerindo a ausência de observações excessivamente influentes.




Figure 6: Gráfico de resíduos padronizados vs. Alavancagem.

### 3.3.4 Independência dos Erros

Para testar a independência dos erros, especialmente em dados de séries temporais, emprega-se o teste de Durbin-Watson. A Figura 7 mostra o resultado do teste.

```
> durbinWatsonTest(analise) # Teste durbin-watson
lag Autocorrelation D-W Statistic p-value
1      0.988233    0.01985623    0
Alternative hypothesis: rho != 0
```

Figure 7: Resultado do Teste de Durbin-Watson.

O teste resultou numa estatística  $D = 0.01985$  com um p-valor de 0, o que rejeita fortemente a hipótese nula de não autocorrelação. Um valor de  $D$  próximo de 0 indica uma forte autocorrelação positiva. Essa correlação é visualmente confirmada pelo gráfico da Função de Autocorrelação (ACF) dos resíduos (Figura 8), onde as autocorrelações decaem muito lentamente.




Figure 8: Função de Autocorrelação (ACF) dos Resíduos.

## 4 Conclusão

A análise de regressão linear simples revelou uma relação positiva e estatisticamente significativa entre os preços do Ouro (GLD) e do Bitcoin (BTC-USD), com o modelo explicando aproximadamente 77.12% da variabilidade nos preços do Bitcoin. Contudo, a análise de diagnóstico indicou problemas. As suposições de linearidade e homocedasticidade foram questionadas, e, mais criticamente, a suposição de independência dos erros foi fortemente violada, conforme indicado pelo teste de Durbin-Watson. Este fato sugere que, para análises preditivas mais robustas, modelos que incorporem a dependência temporal dos dados, como modelos ARIMA ou GARCH, seriam mais adequados.

## References

- [1] Morettin, P. A. and Singer, J. M. (2024). *Estatística e Ciência de Dados*. 2a. Edição. LTC, Rio de Janeiro.
- [2] James, G., Witten, D., Hastie, T. and Tibshirani, R. (2017). *Introduction to Statistical Learning*. Springer.